INSTITUTO SUPERIOR DE ENGENHARIA DO PORTO

DEPARTAMENTO DE ENGENHARIA INFORMÁTICA

Mestrado em Engenharia Informática — 2026/2027 (1º Semestre)

ARMAZÉNS DE DADOS (ARMDD) — TRABALHO PRÁTICO

Conceção do Data Mart de Vendas, Estruturas de Staging Area e Mapeamentos ETL com Alocação de Frete e Tratamento de Deduplicação de Clientes para a **More Rhythm, SA**

Grupo de Trabalho:

- Tiago Daniel Alves Costa — **1230757**
- Martim Araújo — **1260651**

Parte 1 — Especificação

Entrega: 15 de novembro de 2026

Porto, Portugal

Unidade Curricular: Armazéns de Dados (ARMDD)
Curso: Mestrado em Engenharia Informática (MEI) — Instituto Superior de Engenharia do Porto (ISEP)
Ano Letivo: 2026/2027 — 1º Semestre

Grupo de Trabalho:
- **Aluno 1:** Tiago Daniel Alves Costa — `1230757`
- **Aluno 2:** Martim Araújo — `1260651`

---

1. Introdução e Contextualização do Problema

O presente projeto tem por objetivo o desenho e desenvolvimento de um *Data Mart* de apoio à decisão para a empresa **More Rhythm, SA**, líder nacional na distribuição e comercialização de instrumentos musicais, sediada no Porto. A empresa opera em todo o território de Portugal continental e ilhas e, pontualmente, em Espanha.

O sistema de informação operacional da organização (OLTP) suporta as atividades diárias de faturação/vendas, compras a fornecedores e gestão de existências em armazém. A gestão de topo pretende agora dotar a empresa de uma solução analítica e de *Business Intelligence* baseada na metodologia de **Ralph Kimball**, capaz de permitir análises históricas detalhadas e multidimensionais sobre o processo de vendas.

No desenho da solução, foram tidos em conta os seguintes constrangimentos operacionais e de negócio:
1. **Qualidade dos Dados de Clientes:** Existência de potenciais registos duplicados no sistema transacional relativos ao mesmo cliente físico, com identificadores diferentes e grafias não estritamente idênticas (*dirty data* e falta de conformidade de identificação).
2. **Granularidade dos Custos de Expedição:** Os valores de frete/expedição encontram-se faturados globalmente ao nível do cabeçalho da fatura (`invoices`) e não discriminados por cada linha/artigo.
3. **Auditoria Transacional:** Existência de atributos de controlo temporal no sistema de origem (datas e horas de inserção e última alteração: `ousrda` / `ousrho` e `usrdat` / `usrhor`), permitindo suportar extrações incrementais eficientes.
4. **Visão Estratégica Internacional:** Expansão prevista a curto/médio prazo para o Reino Unido (Reino Unido - GBP) e espaço europeu, exigindo uma solução com suporte multi-moeda e uniformização financeira em Euro (`EUR`).

---

2. Arquitetura do Armazém de Dados

A arquitetura concebida segue os princípios de **Ralph Kimball** (*Enterprise Data Warehouse Bus Architecture* com *Dimensional Data Mart* de processo de negócio) combinada com uma **Área de Pré-Tratamento de Dados (Staging Area)** relacional dedicada, estritamente independente e desacoplada da camada analítica de apresentação.

2.1. Visão Geral da Arquitetura



2.2. Descrição das Camadas da Arquitetura

1. **Camada dos Sistemas Fonte (Operational Source Systems):**
2. Base de dados transacional SQL Server (`MoreRhythm`) otimizada para transações ACID (3FN).
3. Integra as tabelas operacionais da atividade: `documentosfacturacao` (cabeçalhos de fatura), `documentosfacturacaolinhas` (linhas de itens faturados), `clientes` , `produtos` , `vendedores` , `fornecedores` , `familias` , `categorias` e `zonas` .
4. Futuras interfaces para taxas de conversão de câmbio cambial para suportar faturação em moeda estrangeira (GBP).
5. **Área de Pré-Tratamento de Dados (Staging Area - SA):**
6. Criada numa base de dados SQL Server física dedicada (`MoreRhythm_SA`), completamente separada dos sistemas de produção e inacessível aos utilizadores analíticos finais.
7. **Tabelas de Extração (Raw):** Tabelas que recebem uma cópia transitória e rápida dos dados do sistema de origem, sem sobrecarregar o motor transacional em horário laboral.
8. **Módulos de Transformação e Limpeza:**
   - **Deduplicação e Tratamento de Clientes:** Aplicação de algoritmos de correlação e agregação (*fuzzy lookup*, limpeza de espaços e normalização de NIF/moradas/contactos) para identificar e consolidar o mesmo cliente que possua múltiplos identificadores na origem.
   - **Alocação Proporcional de Frete:** Rateio dos custos de expedição da fatura pelas respetivas linhas de produtos com base no peso do valor líquido de cada item.
   - **Uniformização Monetária:** Conversão dos montantes para a moeda padrão Euro (`EUR`).
9. **Tabelas de Rejeição de Dados (Audit / Data Quality Errors):** Registos com valores em falta em campos de preenchimento obrigatório, violações de domínio ou quebra de restrições de integridade referencial que não possam ser resolvidos de forma determinística são desviados para tabelas de exceção, garantindo que o *Data Mart* nunca é corrompido com informação inválida.

10. **Camada do Armazém de Dados / Data Mart (`MoreRhythm_DM`):**
11. Modelação estritamente dimensional em **Esquema em Estrela (*Star Schema*)**.
12. **Tabelas de Dimensões:** Guardam o contexto das operações com recurso a **chaves sub-rogadas (*surrogate keys*) inteiras sequenciais**, desacoplando o modelo analítico das chaves primárias do ERP e permitindo a gestão histórica de alterações via estratégias de *Slowly Changing Dimensions* (SCD Tipo 1 e Tipo 2).
13. **Tabela de Factos:** Contém as medidas quantitativas numéricas associadas a cada evento elementar de venda.
14. **Camada de Apresentação e Análise de Negócio:**
15. Ferramenta analítica **Microsoft Power BI**.
16. Disponibilização de métricas de negócio através de linguagem DAX, suporte a navegação hierárquica (*drill-down* e *roll-up*) e resposta cabal às 20 análises analíticas da gestão.

3. Modelo Dimensional (Metodologia de Ralph Kimball)

O desenho do modelo dimensional baseia-se rigorosamente no processo de 4 passos formalizado por **Ralph Kimball**, em estrita conformidade com os conceitos lecionados na unidade curricular (cf. diapositivos 9 a 14 e 38 a 42 de *Dimensional Data Modeling*).

3.1. Aplicação dos 4 Passos de Kimball

Passo 1: Seleção do Processo de Negócio

O processo de negócio escolhido é a **Faturação / Vendas a Clientes** (*Customer Sales Invoicing*). Representa o núcleo das operações geradoras de receita da More Rhythm, SA, respondendo aos requisitos de análise histórica da administração e a todas as questões de negócio enunciadas.

Passo 2: Declaração da Granularidade

A granularidade definida é **uma linha individual de um produto constante numa fatura de venda emitida a um cliente** (*individual line item of a sales invoice*).
- *Justificação Teórica:* Conforme os princípios de Kimball, a adoção da granularidade mais atómica e elementar é a prática recomendada em *Data Warehousing*, pois confere a máxima flexibilidade analítica. Qualquer agregação prematura impediria a realização de consultas analíticas que exigissem o detalhe ao nível do artigo faturado (como a descida de nível / *drill-down* de categoria ou família até ao produto específico, exigida nas análises 5 e 6).

Passo 3: Identificação das Dimensões

As dimensões identificadas fornecem o contexto das medidas numéricas:
1. `Dim_Data`: Registo temporal detalhado da data de emissão do documento de venda.
2. `Dim_Hora`: Registo intradiário (hora e minuto) da transação. Conforme demonstrado na matéria teórica (diapositivo 19), a separação de Data e Hora em duas dimensões distintas previne o crescimento exponencial do número de registos que ocorreria caso fossem unificadas numa única dimensão com granularidade de minuto ou segundo.
3. `Dim_Cliente`: Entidade compradora, agregando os dados cadastrais, a localização e o tipo de cliente.
4. `Dim_Produto`: O produto/instrumento musical comercializado, desnormalizando a hierarquia relacional de origem (`familias` e `categorias`) numa estrutura em estrela limpa.
5. `Dim_Fornecedor`: Entidade fornecedora associada ao produto e respetiva zona geográfica, viabilizando análises de vendas por fornecedor e zona de abastecimento (análises 3 e 10).
6. `Dim_Funcionario`: Colaborador que intermediou ou concretizou a venda.
7. `Dim_Moeda`: Contexto monetário da operação, suportando a futura sucursal no Reino Unido (GBP) e garantindo a uniformização contabilística em Euro (`EUR`).

Passo 4: Identificação dos Factos e Métricas

Na tabela de factos `Fact_Vendas`, são armazenadas as métricas quantitativas associadas a cada linha faturada:
- **Métricas Aditivas:** `Quantidade`, `Preco_Unitario`, `Valor_Venda_Sem_IVA`, `Taxa_IVA`, `Valor_IVA`, `Valor_Venda_Com_IVA`, `Custo_Expedicao_Alocado`, `Valor_Venda_Sem_Frete_Sem_IVA`.
- **Degenerate Dimensions (DD):** `Numero_Fatura` e `Numero_Linha` (preservados diretamente na tabela de factos para rastreabilidade com o sistema transacional sem necessidade de criar uma dimensão dedicada).

3.2. Tratamento dos Custos de Expedição (Alocação de Granularidades Distintas)

No sistema operacional, os custos de transporte/frete encontram-se registados exclusivamente no cabeçalho da fatura (`documentosfacturacao.custo_expedicao`). Todavia, as necessidades de análise da empresa (ex.: análise 2: *"Valores totais dos custos de expedição despendidos no transporte dos produtos durante o mês de fevereiro de 2025, detalhados*

por cidade do cliente e por família de produto") exigem correlacionar o frete com dimensões que apenas existem ao nível da linha (como o Produto e a sua respetiva Família).

Para ultrapassar este desfasamento de granularidade sem gerar redundâncias ou duplicações em agregações, aplica-se a técnica formal de **Alocação de Custos de Cabeçalho para Linha** preconizada por Kimball (diapositivos 39 e 40):

> **Fórmula de Alocação de Frete à Linha (Ralph Kimball):**
> `Custo_Expedicao_Alocado (linha) = Custo_Expedicao (fatura) × [ Valor_Venda_Sem_IVA (linha) / Total_Fatura_Sem_IVA ]`

Nota: Se uma fatura apresentar valor total líquido igual a 0 ou não possuir custos de transporte, o custo alocado à linha assume o valor `0.00`. Esta operação matemática garante que o somatório do frete de todas as linhas de uma fatura corresponde com precisão de cêntimo ao frete total do documento original.

3.3. Especificação Detalhada das Tabelas do Modelo Dimensional

Apresenta-se a especificação completa de atributos, tipos de dados SQL Server, categorização de chaves e regras de negócio para cada tabela do *Data Mart*.

Tabela de Dimensão: `Dim_Data`

Criada para dar suporte a todas as análises temporais e filtros de calendário exigidos pela gestão.

Atributo	Tipo de Dados	Chave	Descrição / Domínio
`Data_Key`	`INT`	**PK / SK**	Chave sub-rogada no formato sequencial inteiro (ex.: `20250115` ou `1, 2, ...`).
`Data_Completa`	`DATE`	—	Data em formato `AAAA-MM-DD`.
`Dia`	`TINYINT`	—	Dia do mês (1 a 31).
`Dia_Semana`	`TINYINT`	—	Dia da semana (1 = Segunda-feira a 7 = Domingo).
`Nome_Dia_Semana`	`NVARCHAR(20)`	—	Nome por extenso (ex.: "Segunda-feira", "Sábado").
`Fim_De_Semana`	`BIT`	—	Indicador de fim de semana (1 = Sábado/Domingo, 0 = Dia útil) — *Análise 10*.
`Semana_Ano`	`TINYINT`	—	Número da semana no ano (1 a 53) — *Análise 6*.
`Mes`	`TINYINT`	—	Mês do ano (1 a 12).
`Nome_Mes`	`NVARCHAR(20)`	—	Designação do mês (ex.: "Fevereiro", "Março").
`Ultimo_Dia_Mes`	`BIT`	—	Indicador de último dia do mês (1 = Sim, 0 = Não) — *Análise 5*.
`Trimestre`	`TINYINT`	—	Trimestre do ano (1 a 4) — *Análises 9 e 10*.
`Nome_Trimestre`	`NVARCHAR(10)`	—	Descrição (ex.: "T1", "T2", "T3", "T4").
`Quadrimestre`	`TINYINT`	—	Quadrimestre do ano (1 a 3) — *Análise 7*.
`Nome_Quadrimestre`	`NVARCHAR(10)`	—	Descrição (ex.: "Q1", "Q2", "Q3").
`Semestre`	`TINYINT`	—	Semestre do ano (1 ou 2) — *Análise 1*.
`Nome_Semestre`	`NVARCHAR(10)`	—	Descrição (ex.: "S1", "S2").
`Ano`	`SMALLINT`	—	Ano civil (ex.: 2025).

Atributo	Tipo de Dados	Chave	Descrição / Domínio
`Estacao_Ano`	`NVARCHAR(15)`	—	Estação do ano ("Primavera", "Verão", "Outono", "Inverno") — *Análise 8*.

Tabela de Dimensão: `Dim_Hora`

Modela a componente temporal intradiária da transação.

Atributo	Tipo de Dados	Chave	Descrição / Domínio
`Hora_Key`	`INT`	**PK / SK**	Chave sub-rogada sequencial (ex.: `0` a `1439` para granularidade ao minuto).
`Hora_Completa`	`TIME(0)`	—	Hora no formato `HH:MM:SS`.
`Hora`	`TINYINT`	—	Hora do dia (0 a 23).
`Minuto`	`TINYINT`	—	Minuto da hora (0 a 59).
`Periodo_Dia`	`NVARCHAR(20)`	—	Segmento horário ("Madrugada", "Manhã", "Tarde", "Noite").

Tabela de Dimensão: `Dim_Cliente`

Armazena os intervenientes compradores, com atributos consolidados pós-deduplicação.

Atributo	Tipo de Dados	Chave	Descrição / Domínio
`Cliente_Key`	`INT`	**PK / SK**	Chave sub-rogada artificial inteira sequencial.
`Cliente_ID_Original`	`INT`	**BK**	Identificador de negócio de origem (`clientes.no`).
`Nome_Cliente`	`NVARCHAR(150)`	—	Nome civil ou empresarial do cliente.
`Tipo_Cliente`	`NVARCHAR(50)`	—	Categoria/tipo de cliente (ex.: "Particular", "Escola", "Profissional") — *Análise 7*.
`Morada`	`NVARCHAR(200)`	—	Morada de faturação/residência.
`Codigo_Postal`	`NVARCHAR(20)`	—	Código postal normalizado.
`Cidade`	`NVARCHAR(100)`	—	Localidade / Cidade — *Análises 2 e 8*.
`Zona`	`NVARCHAR(100)`	—	Zona geográfica (ex.: "Norte", "Centro", "Sul") — *Análises 6, 9 e 10*.
`Pais`	`NVARCHAR(50)`	—	País (ex.: "Portugal", "Espanha").
`Telefone`	`NVARCHAR(30)`	—	Contacto telefónico consolidado.
`Email`	`NVARCHAR(150)`	—	Endereço de correio eletrónico.
`Data_Inicio_Validade`	`DATETIME2`	—	Início de vigência do registo (SCD Tipo 2).
`Data_Fim_Validade`	`DATETIME2`	—	Fim de vigência do registo (SCD Tipo 2; NULL para registo ativo).
`Registo_Atual`	`BIT`	—	Flag de versão ativa (1 = Versão corrente, 0 = Histórico).

Tabela de Dimensão: `Dim_Produto`

Desnormaliza a hierarquia operacional de `produtos`, `familias` e `categorias`.

Atributo	Tipo de Dados	Chave	Descrição / Domínio
`Produto_Key`	`INT`	**PK / SK**	Chave sub-rogada artificial inteira sequencial.
`Referencia_Produto`	`NVARCHAR(50)`	**BK**	Código/referência do produto no ERP (`produtos.ref`).
`Nome_Produto`	`NVARCHAR(150)`	—	Designação comercial do produto.
`Codigo_Familia`	`NVARCHAR(30)`	—	Código da família.
`Nome_Familia`	`NVARCHAR(100)`	—	Família (ex.: "Acessórios", "Amplificadores", "Teclados") — *Análises 2, 6, 8 e 10*.
`Codigo_Categoria`	`NVARCHAR(30)`	—	Código da categoria.
`Nome_Categoria`	`NVARCHAR(100)`	—	Categoria (ex.: "Ar", "Cordas", "Membranas") — *Análises 1, 5 e 9*.
`Unidade_Venda`	`NVARCHAR(20)`	—	Unidade de comercialização (ex.: "UN").
`Preco_Referencia`	`DECIMAL(12,2)`	—	Preço de tabela/referência em Euros.
`Data_Inicio_Validade`	`DATETIME2`	—	Início de vigência do registo (SCD Tipo 2).
`Data_Fim_Validade`	`DATETIME2`	—	Fim de vigência do registo (SCD Tipo 2).
`Registo_Atual`	`BIT`	—	Flag de versão ativa (1 = Atual, 0 = Histórico).

Tabela de Dimensão: `Dim_Fornecedor`

Identifica o fornecedor original do produto e a respetiva localização geográfica de origem.

Atributo	Tipo de Dados	Chave	Descrição / Domínio
`Fornecedor_Key`	`INT`	**PK / SK**	Chave sub-rogada artificial inteira sequencial.
`Fornecedor_ID_Original`	`INT`	**BK**	Identificador de negócio de origem (`fornecedores.no`).
`Nome_Fornecedor`	`NVARCHAR(150)`	—	Razão social do fornecedor — *Análises 3 e 10*.
`Morada`	`NVARCHAR(200)`	—	Morada do fornecedor.
`Cidade`	`NVARCHAR(100)`	—	Cidade do fornecedor.
`Zona_Fornecedor`	`NVARCHAR(100)`	—	Zona geográfica do fornecedor — *Análise 10*.
`Pais`	`NVARCHAR(50)`	—	País sede do fornecedor.
`Email`	`NVARCHAR(150)`	—	Contacto de email do fornecedor.
`Data_Inicio_Validade`	`DATETIME2`	—	Controlo histórico (SCD Tipo 2).
`Data_Fim_Validade`	`DATETIME2`	—	Controlo histórico (SCD Tipo 2).
`Registo_Atual`	`BIT`	—	Flag de versão ativa (1 = Atual, 0 = Histórico).

Tabela de Dimensão: `Dim_Funcionario`

Regista os vendedores/funcionários da empresa.

Atributo	Tipo de Dados	Chave	Descrição / Domínio
`Funcionario_Key`	`INT`	**PK / SK**	Chave sub-rogada artificial inteira sequencial.

Atributo	Tipo de Dados	Chave	Descrição / Domínio
`Funcionario_ID_Original`	`INT`	**BK**	Identificador de negócio (`vendedores.no`).
`Nome_Funcionario`	`NVARCHAR(150)`	—	Nome completo do funcionário — *Análises 3 e 4*.
`Email`	`NVARCHAR(150)`	—	Email corporativo.
`Area_Venda`	`NVARCHAR(100)`	—	Área ou departamento comercial atribuído.
`Data_Inicio_Validade`	`DATETIME2`	—	Controlo histórico (SCD Tipo 2).
`Data_Fim_Validade`	`DATETIME2`	—	Controlo histórico (SCD Tipo 2).
`Registo_Atual`	`BIT`	—	Flag de versão ativa (1 = Atual, 0 = Histórico).

Tabela de Dimensão: `Dim_Moeda`

Suporta a uniformização contábil face à expansão futura.

Atributo	Tipo de Dados	Chave	Descrição / Domínio
`Moeda_Key`	`INT`	**PK / SK**	Chave sub-rogada inteira.
`Codigo_Moeda`	`CHAR(3)`	**BK**	Código ISO 4217 (ex.: `EUR` , `GBP`).
`Nome_Moeda`	`NVARCHAR(50)`	—	Descrição da moeda (ex.: "Euro", "Libra Esterlina").
`Simbolo`	`NVARCHAR(5)`	—	Símbolo monetário (ex.: "€", "£").

Tabela de Factos: `Fact_Vendas`

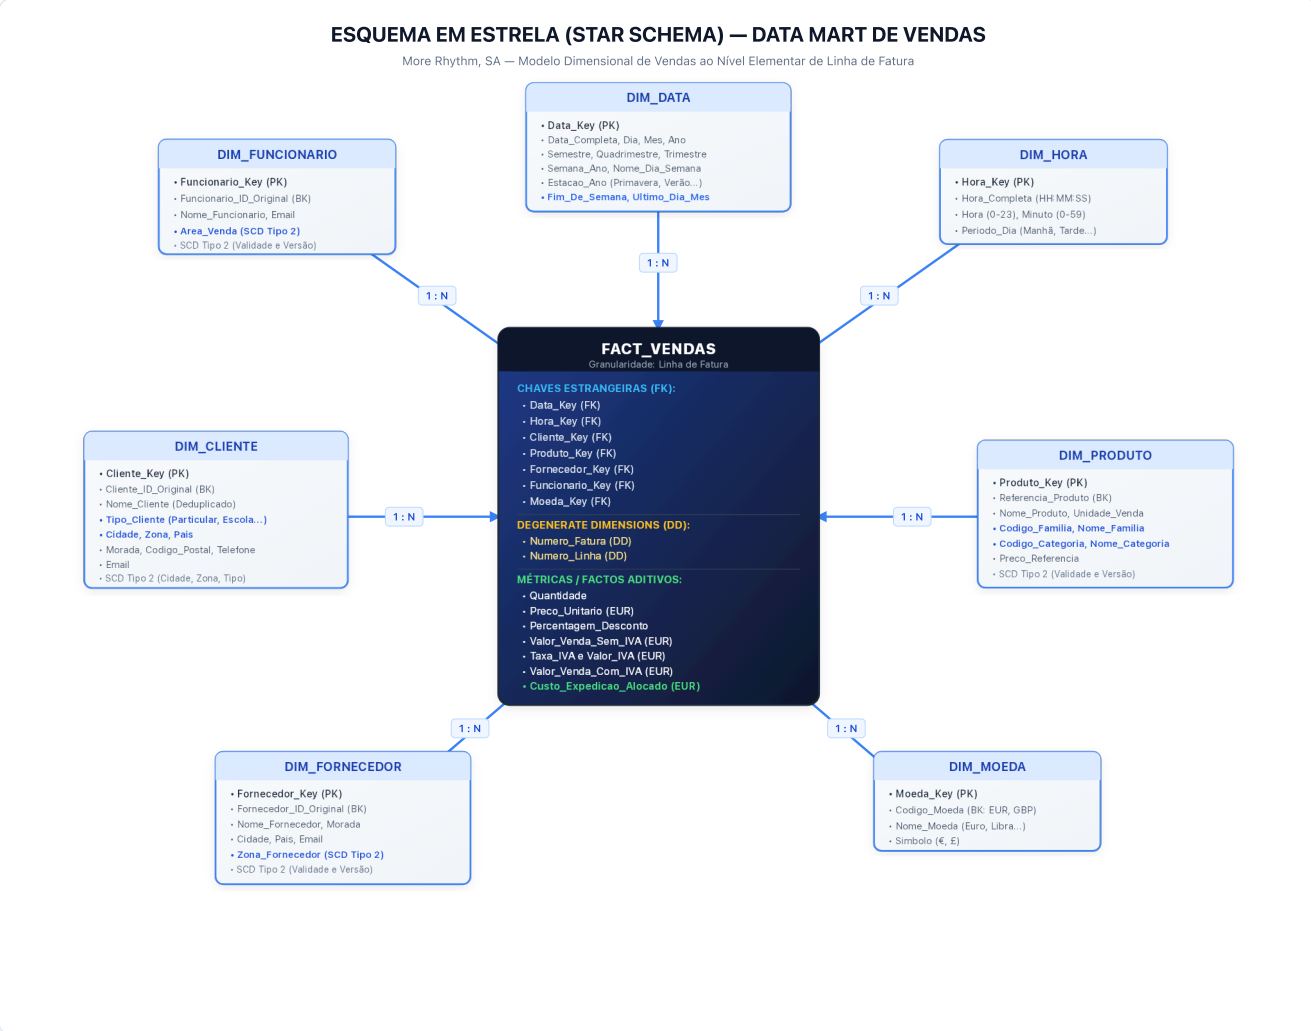
Armazena os eventos quantitativos ao grão de linha de fatura.

Atributo	Tipo de Dados	Chave	Descrição / Domínio
`Data_Key`	`INT`	**FK**	Referência a `Dim_Data` .
`Hora_Key`	`INT`	**FK**	Referência a `Dim_Hora` .
`Cliente_Key`	`INT`	**FK**	Referência a `Dim_Cliente` .
`Produto_Key`	`INT`	**FK**	Referência a `Dim_Produto` .
`Fornecedor_Key`	`INT`	**FK**	Referência a `Dim_Fornecedor` .
`Funcionario_Key`	`INT`	**FK**	Referência a `Dim_Funcionario` .
`Moeda_Key`	`INT`	**FK**	Referência a `Dim_Moeda` .
`Numero_Fatura`	`INT`	**DD**	Degenerate Dimension: Número do documento original.
`Numero_Linha`	`SMALLINT`	**DD**	Degenerate Dimension: Número sequencial da linha.
`Quantidade`	`INT`	**Facto**	Quantidade faturada — *Análises 3, 7 e 10*.
`Preco_Unitario`	`DECIMAL(12,2)`	**Facto**	Preço unitário faturado em Euros.
`Percentagem_Desconto`	`DECIMAL(5,2)`	**Facto**	Percentagem de desconto aplicada na linha (0.00 a 100.00%).
`Valor_Venda_Sem_IVA`	`DECIMAL(14,2)`	**Facto**	Valor líquido faturado em Euros — *Análises 4 e 9*.

Atributo	Tipo de Dados	Chave	Descrição / Domínio
`Taxa_IVA`	`DECIMAL(5,2)`	**Facto**	Taxa de IVA aplicada (ex.: 23.00, 6.00%).
`Valor_IVA`	`DECIMAL(14,2)`	**Facto**	Montante de IVA faturado em Euros — *Análises 4 e 8*.
`Valor_Venda_Com_IVA`	`DECIMAL(14,2)`	**Facto**	Valor bruto total faturado em Euros — *Análises 1, 5, 6 e 10*.
`Custo_Expedicao_Alocado`	`DECIMAL(14,2)`	**Facto**	Parcela proporcional do frete alocada à linha em Euros — *Análise 2*.
`Valor_Venda_Sem_Frete_Sem_IVA`	`DECIMAL(14,2)`	**Facto**	Valor líquido deduzido do custo de frete — *Análise 9*.

3.4. Diagrama Conceptual do Esquema em Estrela (*Star Schema*)

Apresenta-se a representação gráfica do modelo dimensional em estrela (*Star Schema*), evidenciando a tabela de factos central (`Fact_Vendas`) e a sua ligação radial às 7 tabelas de dimensões conformadas em disposição estelar.



Apresenta-se a representação gráfica do modelo dimensional em estrela (*Star Schema*), evidenciando a tabela de factos central (`Fact_Vendas`) e a sua ligação radial às 7 tabelas de dimensões conformadas.

4. Estruturas de Dados a Criar na Staging Area

A Área de Pré-Tratamento (*Staging Area* - SA) é implementada numa base de dados relacional independente (`MoreRhythm_SA`), assegurando o isolamento completo face aos sistemas operacionais de produção e ao modelo dimensional final de consulta.

Para responder às exigências de integridade e eficiência de processamento definidas no enunciado, a *Staging Area* é organizada em três camadas lógicas de estruturas de dados:
1. **Tabelas de Extração Direta (*Raw / Landing Tables*):** Cópia 1:1 transitória dos dados operacionais com metadados de carga.
2. **Tabelas de Transformação e Consolidação (*Clean / Processed Tables*):** Onde ocorrem a deduplicação de registos, desnormalização de hierarquias, alocação de frete e conversão monetária.
3. **Tabelas de Auditoria e Rejeição (*Rejection / Data Quality Tables*):** Destinadas ao isolamento estrito de registos corrompidos ou com violações de regras de negócio cuja correção automática não seja viável, prevenindo a poluição do *Data Mart*.

4.1. Tabelas de Extração Direta (*Raw / Landing Tables*)

Estas tabelas recebem os registos extraídos pelo SSIS a partir do sistema operacional `MoreRhythm`. Possuem uma correspondência direta com as tabelas transacionais de origem, com tipos de dados compatíveis e a adição de um campo de auditoria temporal (`stg_extracted_at`).

Tabela de Extração	Tabela Operacional de Origem	Finalidade / Conteúdo
`stg_raw_clientes`	`clientes`	Registo bruto de clientes e identificadores associados.
`stg_raw_vendedores`	`vendedores`	Registo de funcionários/vendedores e dados cadastrais.
`stg_raw_fornecedores`	`fornecedores`	Registo de fornecedores e localização.
`stg_raw_produtos`	`produtos`	Catálogo de produtos, referências, preços e taxas de IVA.
`stg_raw_familias`	`familias`	Classificação de famílias de instrumentos e equipamentos.
`stg_raw_categorias`	`categorias`	Classificação de categorias de instrumentos musicais.
`stg_raw_zonas`	`zonas`	Zonas geográficas de atuação comercial e fornecimento.
`stg_raw_documentosfacturacao`	`documentosfacturacao`	Cabeçalhos de faturas (data, hora, cliente, funcionário, frete, moeda).
`stg_raw_documentosfacturacaolinhas`	`documentosfacturacaolinhas`	Linhas das faturas emitidas (produto, quantidade, preço, IVA, desconto).
`stg_raw_taxas_cambio`	*Ficheiro / Web Service Externo*	Histórico diário de taxas de conversão de divisas (GBP ➔ EUR).

4.2. Tabelas de Transformação e Consolidação (*Clean / Processed Tables*)

Nestas tabelas intermediárias da *Staging Area*, os dados brutos são submetidos a operações de limpeza, validação, deduplicação e cálculos derivados antes do carregamento nas dimensões e na tabela de factos.

1. `stg_clean_clientes` (Clientes Consolidados e Deduplicados)

Armazena a visão única de cada cliente físico, unificando registos duplicados ou introduzidos com pequenas variações de grafia.

Atributo	Tipo de Dados	Descrição / Transformação Aplicada
`Master_Cliente_ID`	`INT`	Identificador único consolidado atribuído ao cliente físico.
`Cliente_ID_Original`	`INT`	Identificador de origem no sistema operacional (`clientes.no`).
`Nome_Cliente`	`NVARCHAR(150)`	Nome normalizado (sem espaços redundantes, caracteres especiais limpos).
`Tipo_Cliente`	`NVARCHAR(50)`	Tipo de cliente padronizado (com preenchimento de valor por omissão se nulo).
`Morada`	`NVARCHAR(200)`	Morada consolidada e normalizada em maiúsculas/minúsculas.
`Codigo_Postal`	`NVARCHAR(20)`	Código postal formatado (ex.: `XXXX-YYY`).
`Cidade`	`NVARCHAR(100)`	Cidade com grafia uniformizada (resolução de abreviaturas e acentuação).
`Zona`	`NVARCHAR(100)`	Nome da zona geográfica obtido por junção com `stg_raw_zonas` .
`Pais`	`NVARCHAR(50)`	País associado (preenchimento por defeito: "Portugal").
`Telefone`	`NVARCHAR(30)`	Contacto telefónico formatado apenas com dígitos numéricos.
`Email`	`NVARCHAR(150)`	Endereço de email validado sintaticamente e em minúsculas.
`Flag_Deduplicado`	`BIT`	Indica se o registo resultou da fusão de registos redundantes (1 = Sim, 0 = Não).

2. `stg_clean_produtos` (Produtos e Hierarquia Desnormalizada)

Integra a informação de produtos com as respetivas famílias e categorias para povoamento direto de `Dim_Produto` .

Atributo	Tipo de Dados	Descrição / Transformação Aplicada
`Referencia_Produto`	`NVARCHAR(50)`	Referência do produto sem espaços excedentes (`LTRIM` / `RTRIM`).
`Nome_Produto`	`NVARCHAR(150)`	Designação comercial limpa e normalizada.
`Codigo_Familia`	`NVARCHAR(30)`	Código da família.
`Nome_Familia`	`NVARCHAR(100)`	Nome da família (ex.: "Acessórios", "Amplificadores", "Teclados").
`Codigo_Categoria`	`NVARCHAR(30)`	Código da categoria.
`Nome_Categoria`	`NVARCHAR(100)`	Nome da categoria (ex.: "Ar", "Cordas", "Membranas").
`Fornecedor_ID_Original`	`INT`	Identificador do fornecedor associado ao produto.
`Unidade_Venda`	`NVARCHAR(20)`	Unidade comercial padrão (ex.: "UN").
`Preco_Referencia`	`DECIMAL(12,2)`	Preço de tabela validado como positivo (> 0.00).

3. `stg_clean_vendas` (Linhas de Fatura com Frete Alocado e Moeda Convertida)

Tabela resultante da junção de cabeçalhos e linhas de fatura, onde é aplicado o cálculo de rateio de frete e a uniformização para Euros.

Atributo	Tipo de Dados	Descrição / Transformação Aplicada
`Numero_Fatura`	`INT`	Número da fatura de venda (`documentosfacturacao.fno`).
`Numero_Linha`	`SMALLINT`	Linha da fatura (`documentosfacturacaolinhas.linha`).
`Data_Fatura`	`DATE`	Data de emissão da fatura.
`Hora_Fatura`	`TIME(0)`	Hora de emissão da fatura.
`Cliente_ID_Original`	`INT`	Identificador do cliente da fatura (ligado a `Master_Cliente_ID`).
`Referencia_Produto`	`NVARCHAR(50)`	Referência do produto vendido.
`Funcionario_ID_Original`	`INT`	Identificador do funcionário que efetuou a venda.
`Moeda_Original`	`CHAR(3)`	Código da divisa original (`EUR` , `GBP`).
`Taxa_Cambio_Aplicada`	`DECIMAL(10,4)`	Taxa de conversão para Euro na data da fatura (1.0000 para `EUR`).
`Quantidade`	`INT`	Quantidade faturada (validada como estritamente positiva > 0).
`Preco_Unitario_EUR`	`DECIMAL(12,2)`	Preço unitário convertido para Euros: Preço Unitário × Taxa de Câmbio.
`Percentagem_Desconto`	`DECIMAL(5,2)`	Desconto da linha em percentagem (0.00% a 100.00%).
`Valor_Venda_Sem_IVA_EUR`	`DECIMAL(14,2)`	Valor líquido faturado em Euros com desconto deduzido.
`Taxa_IVA`	`DECIMAL(5,2)`	Taxa de IVA aplicada (validada de acordo com as taxas legais).
`Valor_IVA_EUR`	`DECIMAL(14,2)`	Montante do imposto faturado em Euros.
`Valor_Venda_Com_IVA_EUR`	`DECIMAL(14,2)`	Valor bruto total faturado em Euros (Valor Sem IVA + Valor IVA).
`Custo_Expedicao_Alocado_EUR`	`DECIMAL(14,2)`	Frete rateado para a linha em Euros (fórmula de alocação de Kimball).
`Valor_Sem_Frete_Sem_IVA_EUR`	`DECIMAL(14,2)`	Montante líquido deduzido do frete em Euros.

4.3. Tabelas de Auditoria e Rejeição (*Rejection / Data Quality Tables*)

Em estrito cumprimento do requisito do trabalho:

> *"O processo de transformação e limpeza deve filtrar todos os registos que se encontram afetados por problemas de qualidade. Assim, qualquer registo afetado por problemas de qualidade, cuja correção não seja possível de ser automatizável, não deve ser carregado no data mart, sendo armazenado em tabelas especialmente criadas para o efeito na Staging Area."*

São criadas tabelas de rejeição com estrutura idêntica aos registos de entrada, acrescidas de metadados de auditoria (`Erro_Codigo` , `Erro_Descricao` , `Data_Rejeicao` , `Origem_Ficheiro_Tabela`):

1. `err_clientes` (Rejeições de Clientes)

- **Motivos de Rejeição Não Automatizáveis:**
- `ERR_CLI_01` : Nome do cliente inexistente, nulo ou constituído apenas por espaços em branco.

- `ERR_CLI_02`: Inconsistência grave ou ausência de zona geográfica que impossibilite mapeamento com o catálogo de zonas.
- `ERR_CLI_03`: Conflito insolúvel entre dados cadastrais obrigatórios.

Atributo	Tipo de Dados	Descrição
`Erro_ID`	`INT IDENTITY(1,1)`	Chave primária da tabela de erro.
`Cliente_ID_Original`	`INT`	Identificador de negócio de origem.
`Nome_Cliente_Raw`	`NVARCHAR(150)`	Nome recebido na extração.
`Morada_Raw`	`NVARCHAR(200)`	Morada recebida.
`Zona_Raw`	`NVARCHAR(100)`	Zona recebida.
`Erro_Codigo`	`VARCHAR(20)`	Código identificador do tipo de anomalia.
`Erro_Descricao`	`NVARCHAR(255)`	Descrição detalhada do erro detetado.
`Data_Rejeicao`	`DATETIME2`	Data e hora em que a rejeição ocorreu.

2. `err_produtos` (Rejeições de Produtos)

- **Motivos de Rejeição Não Automatizáveis:**
- `ERR_PRD_01`: Referência de produto nula ou vazia.
- `ERR_PRD_02`: Preço de referência negativo ou valor absurdo.
- `ERR_PRD_03`: Referência a código de Família ou Categoria inexistente no sistema operacional (quebra de integridade referencial).
- `ERR_PRD_04`: Fornecedor associado ao produto inexistente.

Atributo	Tipo de Dados	Descrição
`Erro_ID`	`INT IDENTITY(1,1)`	Chave primária do erro.
`Referencia_Produto_Raw`	`NVARCHAR(50)`	Código do produto original.
`Designacao_Raw`	`NVARCHAR(150)`	Nome ou descrição original.
`Familia_Raw`	`NVARCHAR(50)`	Código de família original.
`Categoria_Raw`	`NVARCHAR(50)`	Código de categoria original.
`Preco_Raw`	`DECIMAL(12,2)`	Preço rejeitado.
`Erro_Codigo`	`VARCHAR(20)`	Código identificador da anomalia.
`Erro_Descricao`	`NVARCHAR(255)`	Descrição do motivo de descarte.
`Data_Rejeicao`	`DATETIME2`	Data e hora de registo da exceção.

3. `err_vendas` (Rejeições de Transações de Venda / Faturação)

- **Motivos de Rejeição Não Automatizáveis:**
- `ERR_VND_01`: Fatura com referência a um cliente inexistente ou previamente rejeitado por falta de integridade.
- `ERR_VND_02`: Linha de fatura referenciando um produto inexistente na tabela de produtos válidos.
- `ERR_VND_03`: Quantidade faturada menor ou igual a zero (≤ 0).
- `ERR_VND_04`: Preço unitário negativo ou valor total líquido inconsistente.

- `ERR_VND_05`: Inconsistência matemática grave entre o somatório das linhas e o valor do cabeçalho da fatura superior a tolerância admissível de arredondamento cambial.
- `ERR_VND_06`: Taxa de câmbio inexistente para a data da transação (para operações em GBP).

Atributo	Tipo de Dados	Descrição
`Erro_ID`	`INT IDENTITY(1,1)`	Chave primária do erro.
`Numero_Fatura_Raw`	`INT`	Número da fatura transacional.
`Numero_Linha_Raw`	`SMALLINT`	Número de linha da fatura.
`Data_Fatura_Raw`	`DATE`	Data da fatura original.
`Cliente_ID_Raw`	`INT`	Código de cliente original.
`Produto_Ref_Raw`	`NVARCHAR(50)`	Referência de produto original.
`Quantidade_Raw`	`INT`	Quantidade original.
`Total_Linha_Raw`	`DECIMAL(14,2)`	Total faturado da linha.
`Erro_Codigo`	`VARCHAR(20)`	Código do erro detetado.
`Erro_Descricao`	`NVARCHAR(255)`	Descrição do problema que ditou a rejeição.
`Data_Rejeicao`	`DATETIME2`	Timestamp de auditoria da rejeição.

5. Mapeamento de Dados e Estratégias de Slowly Changing Dimensions (SCD)

Em conformidade com os requisitos da 1ª parte do trabalho, apresenta-se o mapeamento detalhado entre os sistemas fonte e a *Staging Area* (T4) e entre a *Staging Area* e o *Data Mart* (T5), explicitando a estratégia de **Slowly Changing Dimension (SCD)** adotada para cada atributo das dimensões (cf. diapositivos 27 a 37 da matéria teórica de *Dimensional Data Modeling*).

5.1. Mapeamento Sistemas Fonte ➔ Staging Area (T4)

A extração das tabelas da base de dados operacional `MoreRhythm` para a base de dados `MoreRhythm_SA` é concebida para suportar execuções de carga inicial (*Full Load*) e execuções de carga incremental (*Delta Load*), tirando partido dos atributos de auditoria existentes no sistema transacional (`ousrda` / `ousrho` para inserções e `usrdat` / `usrhor` para atualizações).

Origem (`MoreRhythm`)	Destino (`MoreRhythm_SA`)	Tipo de Carga	Regra de Filtro Incremental (SSIS)
`clientes`	`stg_raw_clientes`	Incremental	`usrdat >= ? OR ousrda >= ?`
`produtos`	`stg_raw_produtos`	Incremental	`usrdat >= ? OR ousrda >= ?`
`vendedores`	`stg_raw_vendedores`	Incremental	`usrda >= ? OR ousrd >= ?`
`fornecedores`	`stg_raw_fornecedores`	Incremental	`usrdat >= ? OR ousrda >= ?`
`familias`	`stg_raw_familias`	Total	Tabela de baixa cardinalidade (Truncate & Load).
`categorias`	`stg_raw_categorias`	Total	Tabela de baixa cardinalidade (Truncate & Load).
`zonas`	`stg_raw_zonas`	Total	Tabela de baixa cardinalidade (Truncate & Load).
`documentosfacturacao`	`stg_raw_documentosfacturacao`	Incremental	`usrdat >= ? OR ousrda >= ?`
`documentosfacturacaolinhas`	`stg_raw_documentosfacturacaolinhas`	Incremental	`usrdat >= ? OR ousrda >= ?`
Taxas de Câmbio (Fonte Externa)	`stg_raw_taxas_cambio`	Incremental	Novas cotações diárias adicionadas por data.

5.2. Mapeamento Staging Area ➔ Armazém de Dados e Estratégia SCD (T5)

A metodologia de Kimball define várias técnicas para o tratamento de dimensões que sofrem alterações ao longo do tempo (*Slowly Changing Dimensions*). No nosso modelo, aplicamos uma abordagem híbrida:

- **SCD Tipo 0 (Retain Original):** O valor original do atributo nunca é modificado (imutabilidade). Aplica-se a chaves de negócio e datas de criação.
- **SCD Tipo 1 (Overwrite):** O valor anterior é sobrescrito pelo novo valor. Não há preservação de histórico. Aplica-se à correção de gralhas tipográficas ou atributos de contacto que não possuem relevância para agregação histórica.
- **SCD Tipo 2 (Add New Row):** É inserida uma nova linha na dimensão com uma nova chave sub-rogada (*Surrogate Key*), marcando a versão anterior como expirada (`Data_Fim_Validade`) e inativa (`Registo_Atual = 0`), e a nova como ativa (`Data_Inicio_Validade` , `Data_Fim_Validade = NULL` , `Registo_Atual = 1`). Permite rastrear com precisão a que contexto histórico pertence cada venda passada.

1. Mapeamento e SCD para `Dim_Cliente`

Atributo Destino (`Dim_Cliente`)	Origem na Staging (`stg_clean_clientes`)	Transformação / Expressão	Tipo SCD	Justificação da Opção SCD
`Cliente_Key`	*Sequência do Sistema*	Chave sub-rogada sequencial inteira	—	Surrogate Key padrão de Kimball.
`Cliente_ID_Original`	`Master_Cliente_ID`	Identificador único consolidado	**Tipo 0**	Identificador estável de negócio.
`Nome_Cliente`	`Nome_Cliente`	Normalização de maiúsculas/minúsculas	**Tipo 1**	Correção de gralhas ou pequenos ajustes nominais sem relevância temporal.
`Tipo_Cliente`	`Tipo_Cliente`	Padronização com default "Indefinido"	**Tipo 2**	Uma mudança de tipo (ex.: de Particular para Profissional) deve manter as vendas antigas no tipo antigo (*Análise 7*).
`Morada`	`Morada`	Limpeza de espaços redundantes	**Tipo 1**	Mudança puramente postal ou correção de morada.
`Codigo_Postal`	`Codigo_Postal`	Validação de formato (ex.: 0000-000)	**Tipo 1**	Ajuste cadastral de código postal.
`Cidade`	`Cidade`	Limpeza de acentos e abreviaturas	**Tipo 2**	Mudança de residência/cidade afeta análises geográficas de custos e vendas (*Análises 2 e 8*).
`Zona`	`Zona`	Lookup em `stg_raw_zonas`	**Tipo 2**	Fundamental para preservar a afetação histórica de vendas por zona (*Análises 6, 9 e 10*).
`Pais`	`Pais`	Default "Portugal" ou "Espanha"	**Tipo 2**	Expansão internacional de clientes.
`Telefone`	`Telefone`	Apenas algarismos numéricos	**Tipo 1**	Atualização de contacto corrente.
`Email`	`Email`	Conversão para minúsculas	**Tipo 1**	Atualização de contacto corrente.
`Data_Inicio_Validade`	`stg_extracted_at`	Data/hora de entrada em vigor	—	Metadado de suporte a SCD Tipo 2.

Atributo Destino (`Dim_Cliente`)	Origem na Staging (`stg_clean_clientes`)	Transformação / Expressão	Tipo SCD	Justificação da Opção SCD
`Data_Fim_Validade`	*Controlo ETL*	`NULL` (ativo) ou data da alteração	—	Metadado de suporte a SCD Tipo 2.
`Registo_Atual`	*Controlo ETL*	`1` (versão ativa) ou `0` (histórico)	—	Metadado de suporte a SCD Tipo 2.

2. Mapeamento e SCD para `Dim_Produto`

Atributo Destino (`Dim_Produto`)	Origem na Staging (`stg_clean_produtos`)	Transformação / Expressão	Tipo SCD	Justificação da Opção SCD
`Produto_Key`	*Sequência do Sistema*	Chave sub-rogada sequencial inteira	—	Surrogate Key.
`Referencia_Produto`	`Referencia_Produto`	`UPPER(RTRIM(LTRIM(ref)))`	**Tipo 0**	Código identificador imutável do produto.
`Nome_Produto`	`Nome_Produto`	Limpeza de caracteres especiais	**Tipo 1**	Correção da descrição comercial do artigo.
`Codigo_Familia`	`Codigo_Familia`	Código da família associada	**Tipo 2**	Reclassificação de família tem de preservar vendas passadas na família de origem (*Análises 2, 6, 8 e 10*).
`Nome_Familia`	`Nome_Familia`	Lookup em `stg_raw_familias`	**Tipo 2**	Descrição da família no histórico.
`Codigo_Categoria`	`Codigo_Categoria`	Código da categoria	**Tipo 2**	Reclassificação de categoria deve manter as métricas históricas na categoria correta (*Análises 1, 5 e 9*).
`Nome_Categoria`	`Nome_Categoria`	Lookup em `stg_raw_categorias`	**Tipo 2**	Nome da categoria no histórico.
`Unidade_Venda`	`Unidade_Venda`	Default "UN"	**Tipo 1**	Correção de unidade de medida.
`Preco_Referencia`	`Preco_Referencia`	Preço de tabela	**Tipo 1**	Preço de referência atual (o preço real praticado fica gravado na tabela de factos).
`Data_Inicio_Validade`	`stg_extracted_at`	Data/hora de início	—	Suporte a SCD Tipo 2.
`Data_Fim_Validade`	*Controlo ETL*	`NULL` ou data de encerramento	—	Suporte a SCD Tipo 2.
`Registo_Atual`	*Controlo ETL*	`1` ou `0`	—	Suporte a SCD Tipo 2.

3. Mapeamento e SCD para `Dim_Fornecedor`

Atributo Destino (`Dim_Fornecedor`)	Origem na Staging (`stg_raw_fornecedores`)	Transformação / Expressão	Tipo SCD	Justificação da Opção SCD
`Fornecedor_Key`	*Sequência do Sistema*	Chave sub-rogada sequencial inteira	—	Surrogate Key.
`Fornecedor_ID_Original`	`fornecedores.no`	Identificador operacional	**Tipo 0**	Imutável.
`Nome_Fornecedor`	`fornecedores.nome`	Limpeza de espaços em branco	**Tipo 1**	Correção da designação do fornecedor.
`Morada`	`fornecedores.morada`	Padronização de endereço	**Tipo 1**	Atualização cadastral.
`Cidade`	`fornecedores.local`	Uniformização de grafia	**Tipo 1**	Atualização cadastral.
`Zona_Fornecedor`	`zonas.design`	Lookup via `fornecedores.zona`	**Tipo 2**	A alteração da zona de abastecimento de um fornecedor deve preservar o histórico para relatórios (*Análises 3 e 10*).
`Pais`	`fornecedores.pais`	Default "Portugal"	**Tipo 1**	Atualização cadastral.
`Email`	`fornecedores.email`	Validação de sintaxe e minúsculas	**Tipo 1**	Atualização de contacto.
`Data_Inicio_Validade`	`stg_extracted_at`	Início de vigência	—	Suporte a SCD Tipo 2.
`Data_Fim_Validade`	*Controlo ETL*	Fim de vigência	—	Suporte a SCD Tipo 2.
`Registo_Atual`	*Controlo ETL*	Flag de versão ativa	—	Suporte a SCD Tipo 2.

4. Mapeamento e SCD para `Dim_Funcionario`

Atributo Destino (`Dim_Funcionario`)	Origem na Staging (`stg_raw_vendedores`)	Transformação / Expressão	Tipo SCD	Justificação da Opção SCD
`Funcionario_Key`	*Sequência do Sistema*	Chave sub-rogada sequencial inteira	—	Surrogate Key.
`Funcionario_ID_Original`	`vendedores.no`	Identificador operacional	**Tipo 0**	Imutável.
`Nome_Funcionario`	`vendedores.nome`	Limpeza e capitalização do nome	**Tipo 1**	Correção de gralha no nome.
`Email`	`vendedores.email`	Conversão para minúsculas	**Tipo 1**	Atualização de correio eletrónico.

Atributo Destino (`Dim_Funcionario`)	Origem na Staging (`stg_raw_vendedores`)	Transformação / Expressão	Tipo SCD	Justificação da Opção SCD
`Area_Venda`	`vendedores.area`	Área funcional atribuída	**Tipo 2**	Mudança de departamento comercial deve manter as vendas passadas na área em que foram concretizadas (*Análises 3 e 4*).
`Data_Inicio_Validade`	`stg_extracted_at`	Início de vigência	—	Suporte a SCD Tipo 2.
`Data_Fim_Validade`	*Controlo ETL*	Fim de vigência	—	Suporte a SCD Tipo 2.
`Registo_Atual`	*Controlo ETL*	Flag de versão ativa	—	Suporte a SCD Tipo 2.

5. Mapeamento para `Dim_Moeda`

Tabela estática de domínio/lookup. Não sujeita a SCD, povoada com os códigos ISO 4217 suportados (`EUR` e `GBP`).

5.3. Mapeamento para a Tabela de Factos: `Fact_Vendas`

O carregamento da tabela de factos é realizado exclusivamente a partir da tabela intermédia tratada `stg_clean_vendas`, procedendo à resolução de todas as chaves sub-rogadas ativas à data da venda (*Surrogate Key Lookup*):

Atributo Destino (`Fact_Vendas`)	Origem na Staging (`stg_clean_vendas`)	Transformação / Resolução de Chave (SSIS)
`Data_Key`	`Data_Fatura`	Conversão para formato inteiro: `YEAR * 10000 + MONTH * 100 + DAY`.
`Hora_Key`	`Hora_Fatura`	Lookup em `Dim_Hora` por `Hora_Completa` (ou cálculo `DATEPART(hh)*60 + DATEPART(mi)`).
`Cliente_Key`	`Cliente_ID_Original`	Lookup em `Dim_Cliente` onde `Cliente_ID_Original = stg_clean_vendas.Cliente_ID_Original` e `Data_Fatura BETWEEN Data_Inicio_Validade AND ISNULL(Data_Fim_Validade, '9999-12-31')` .
`Produto_Key`	`Referencia_Produto`	Lookup em `Dim_Produto` onde `Referencia_Produto = stg_clean_vendas.Referencia_Produto` e `Data_Fatura BETWEEN Data_Inicio_Validade AND ISNULL(Data_Fim_Validade, '9999-12-31')` .
`Fornecedor_Key`	`Referencia_Produto`	Lookup ao fornecedor ativo associado ao produto na data da venda em `Dim_Fornecedor`.
`Funcionario_Key`	`Funcionario_ID_Original`	Lookup em `Dim_Funcionario` onde `Funcionario_ID_Original = stg_clean_vendas.Funcionario_ID_Original` e `Data_Fatura BETWEEN Data_Inicio_Validade AND ISNULL(Data_Fim_Validade, '9999-12-31')` .

Atributo Destino (`Fact_Vendas`)	Origem na Staging (`stg_clean_vendas`)	Transformação / Resolução de Chave (SSIS)
`Moeda_Key`	`Moeda_Original`	Lookup em `Dim_Moeda` onde `Codigo_Moeda = stg_clean_vendas.Moeda_Original`.
`Numero_Fatura`	`Numero_Fatura`	Degenerate Dimension: Atribuição direta.
`Numero_Linha`	`Numero_Linha`	Degenerate Dimension: Atribuição direta.
`Quantidade`	`Quantidade`	Atribuição direta (validada > 0).
`Preco_Unitario`	`Preco_Unitario_EUR`	Preço unitário convertido em Euros.
`Percentagem_Desconto`	`Percentagem_Desconto`	Percentagem aplicada na linha.
`Valor_Venda_Sem_IVA`	`Valor_Venda_Sem_IVA_EUR`	Montante líquido faturado em Euros.
`Taxa_IVA`	`Taxa_IVA`	Taxa de imposto percentual.
`Valor_IVA`	`Valor_IVA_EUR`	Montante de IVA faturado em Euros.
`Valor_Venda_Com_IVA`	`Valor_Venda_Com_IVA_EUR`	Montante bruto total em Euros.
`Custo_Expedicao_Alocado`	`Custo_Expedicao_Alocado_EUR`	Montante do frete proporcional rateado em Euros.
`Valor_Venda_Sem_Frete_Sem_IVA`	`Valor_Sem_Frete_Sem_IVA_EUR`	Valor Venda Sem IVA - Custo Expedição Alocado.

6. Operações de Transformação e Limpeza de Dados

Nesta secção detalham-se as regras e algoritmos concebidos para mitigar as patologias de qualidade de dados apontadas no enunciado e na matéria pedagógica da disciplina.

6.1. Deduplicação e Limpeza de Redundâncias de Clientes

O enunciado salienta que *"o mesmo cliente pode ter sido introduzido erradamente em duplicado, estando representado com identificadores diferentes na base de dados... de uma forma que não é rigorosamente igual"*.

Para solucionar este desafio, o fluxo de ETL na *Staging Area* adota um pipeline em quatro fases:
1. **Pré-Processamento e Normalização Sintática:**
- Remoção de espaços supérfluos no início, fim e interior dos textos (`LTRIM`, `RTRIM`, substituição de duplos espaços por espaço simples).
- Conversão de nomes e moradas para caixa consistente.
- Remoção de caracteres especiais e acentuação gráfica para efeito de comparação (ex.: "João" ➔ "JOAO").
- Limpeza e extração apenas de dígitos numéricos em números de telefone/telemóvel e números de identificação fiscal (NIF).
2. **Identificação Determinística e Agrupamento Exato:**
- Registos que partilhem o mesmo NIF válido ou o mesmo número de telefone móvel com morada e código postal idênticos são imediatamente agrupados sob o mesmo `Master_Cliente_ID`.
3. **Correspondência Aproximada (*Fuzzy Matching*):**
- Para clientes com identificadores distintos cujos contactos não correspondam a 100%, recorre-se ao componente **Fuzzy Grouping / Fuzzy Lookup** do SSIS, baseado na distância de similaridade de Jaro-Winkler e Levenshtein:
- Critérios de comparação: `Nome_Cliente` (limiar de similaridade ≥ 0.85), `Morada` (limiar ≥ 0.80) e `Codigo_Postal`.
- Caso o algoritmo detete uma correspondência com índice de confiança superior a 85%, os registos são agregados sob o registo mais antigo (`MIN(Cliente_ID_Original)`), assinalando a flag `Flag_Deduplicado = 1`.
4. **Resolução de Chaves na Faturação:**
- No carregamento de `stg_clean_vendas`, o identificador do cliente da fatura é remapeado para o respetivo `Master_Cliente_ID`, garantindo que todas as compras de um cliente com múltiplos perfis operacionais convergem para uma entidade consolidada na `Dim_Cliente`.

6.2. Algoritmo de Alocação de Frete (Custos de Expedição da Fatura)

Para garantir que as análises analíticas multidimensionais por família de produto, produto ou cidade (como a análise 2 e 8) refletem com rigor os custos de expedição despendidos no transporte sem distorções:
1. Durante a extração para a *Staging Area*, calcula-se o total líquido de todas as linhas de cada fatura:

> `Total_Liquido_Fatura = Soma de todos os [ Valor_Venda_Sem_IVA ] das linhas da fatura`
> 2. Para cada linha *i* da fatura, o custo de expedição proporcional é atribuído através da fórmula:
> `Custo_Expedicao_Alocado (linha i) = Custo_Expedicao (fatura) × [ Valor_Venda_Sem_IVA (linha i) / Total_Liquido_Fatura ]`
> *(Se o total líquido da fatura for igual a zero ou nulo, o custo alocado à linha assume `0.00`).*
> 3. O arredondamento é processado a duas casas decimais (`DECIMAL(14,2)`). Caso ocorra uma diferença residual de cêntimos por arredondamento, essa diferença é ajustada na linha de maior montante da fatura, assegurando a conservação exata da soma:
> `Soma de [ Custo_Expedicao_Alocado ] de todas as linhas = Custo_Expedicao total da fatura`

6.3. Suporte Multi-Moeda e Uniformização Financeira em Euro (EUR)

Face à perspetiva de expansão internacional para o Reino Unido (GBP):
1. **Registo na Tabela de Factos:** Todos os valores quantitativos monetários (`Preco_Unitario` , `Valor_Venda_Sem_IVA` , `Valor_IVA` , `Valor_Venda_Com_IVA` , `Custo_Expedicao_Alocado`) são obrigatoriamente convertidos e armazenados em **Euros (`EUR`)**, garantindo que as agregações contábeis e somatórios são matematicamente válidos.
2. **Conversão Cambial Pontual:**
- No processamento da fatura em `stg_clean_vendas` , é efetuado um *Lookup* à tabela `stg_raw_taxas_cambio` com base na data de emissão do documento (`Data_Fatura`) e na divisa (`Moeda_Original`).
- Valor em EUR = Valor Original × Taxa de Câmbio.
- Se a moeda original for `EUR` , a taxa aplicada é estritamente $11.0000.
3. **Preservação do Contexto da Moeda Original:**
- A chave estrangeira `Moeda_Key` aponta para a `Dim_Moeda` , preservando a informação de qual a moeda na qual a venda foi originariamente celebrada.

6.4. Política de Tratamento de Dados Inválidos e Rejeição

Os dados afetados por anomalias não corrigíveis de forma determinística são filtrados antes de atingir o *Data Mart*:
- Registos com `Quantidade <= 0` , `Preço Unitário < 0` , chaves estrangeiras órfãs (cliente ou produto inexistente na fonte) são imediatamente inseridos em `err_vendas` .
- Clientes com nomes em branco ou valores corrompidos são desviados para `err_clientes` .
- Desta forma, o *Data Mart* preserva conformidade total com as restrições de integridade referencial e domínios numéricos, salvaguardando a confiança dos relatórios analíticos de gestão.

---

7. Matriz de Validação do Modelo face às Consultas Analíticas Indicativas

Para demonstrar a aptidão técnica do modelo dimensional concebido face às solicitações reais da administração da More Rhythm, SA, apresenta-se a matriz de rastreabilidade entre as **10 análises indicativas enunciadas** e as dimensões, hierarquias e métricas do nosso esquema em estrela:

#	Pergunta de Negócio / Análise Indicativa	Dimensões e Hierarquias Utilizadas	Métricas e Factos Aplicados	Capacidade Analítica / Operações Suportadas
1	Valores totais com IVA das vendas no 1º semestre de 2025 por zona e categoria.	`Dim_Data` (`Ano`, `Semestre`), `Dim_Cliente` (`Zona`), `Dim_Produto` (`Nome_Categoria`)	`SUM(Valor_Venda_Com_IVA)`	Filtro por Semestre 1 e Ano 2025; agregação direta por Zona geográfica e Categoria.
2	Valores totais dos custos de expedição (frete) em fevereiro de 2025 por cidade do cliente e família de produto.	`Dim_Data` (`Ano`, `Mes`), `Dim_Cliente` (`Cidade`), `Dim_Produto` (`Nome_Familia`)	`SUM(Custo_Expedicao_Alocado)`	Viabilizado pela alocação proporcional de frete à linha de produto; agregação por Cidade e Família.
3	Quantidades vendidas no 1º trimestre de 2025 por fornecedor e por empregado.	`Dim_Data` (`Ano`, `Trimestre`), `Dim_Fornecedor` (`Nome_Fornecedor`), `Dim_Funcionario` (`Nome_Funcionario`)	`SUM(Quantidade)`	Filtro por T1 2025; cruzamento bidimensional Fornecedor × Funcionário vendedor.
4	Valores totais das vendas sem IVA e respetivo IVA pago em 2025 por cliente e funcionário.	`Dim_Data` (`Ano`), `Dim_Cliente` (`Nome_Cliente`), `Dim_Funcionario` (`Nome_Funcionario`)	`SUM(Valor_Venda_Sem_IVA)`, `SUM(Valor_IVA)`	Apresentação simultânea de valor líquido e imposto; clientes consolidados pós-deduplicação.
5	Vendas com IVA no último dia de cada mês de 2025 por categoria com *drill down* até ao produto.	`Dim_Data` (`Ano`, `Mes`, `Ultimo_Dia_Mes`), `Dim_Produto` (`Nome_Categoria` ➔ `Nome_Produto`)	`SUM(Valor_Venda_Com_IVA)`	Filtro booleano `Ultimo_Dia_Mes = 1`; suporte nativo a *drill down* na hierarquia de produto.
6	Vendas com IVA a clientes da zona Norte na 6ª semana de 2025 por família com *drill down* até produto.	`Dim_Data` (`Ano`, `Semana_Ano`), `Dim_Cliente` (`Zona`), `Dim_Produto` (`Nome_Familia` ➔ `Nome_Produto`)	`SUM(Valor_Venda_Com_IVA)`	Filtro por `Zona = 'Norte'` e `Semana_Ano = 6`; navegação hierárquica Família ➔ Produto.

#	Pergunta de Negócio / Análise Indicativa	Dimensões e Hierarquias Utilizadas	Métricas e Factos Aplicados	Capacidade Analítica / Operações Suportadas
7	Quantidades no 1º quadrimestre de 2025 por cliente e produto com *roll up* até tipo de cliente.	`Dim_Data` (`Ano` , `Quadrimestre`), `Dim_Cliente` (`Tipo_Cliente` ➔ `Nome_Cliente`), `Dim_Produto` (`Nome_Produto`)	`SUM(Quantidade)`	Filtro por `Quadrimestre = 1` ; suporte a agregação (*roll up*) ao nível do `Tipo_Cliente` .
8	Valores de IVA faturados durante a primavera de 2025 por cidade do cliente e família de produto.	`Dim_Data` (`Ano` , `Estacao_Ano`), `Dim_Cliente` (`Cidade`), `Dim_Produto` (`Nome_Familia`)	`SUM(Valor_IVA)`	Filtro por `Estacao_Ano = 'Primavera'` ; agregação por Cidade do comprador e Família.
9	Vendas sem IVA e sem frete por cliente (*roll up* para zona) e por mês (*roll up* para trimestre) para as categorias "Ar", "Cordas" e "Membranas".	`Dim_Cliente` (`Zona` ➔ `Nome_Cliente`), `Dim_Data` (`Ano` , `Trimestre` ➔ `Nome_Mes`), `Dim_Produto` (`Nome_Categoria`)	`SUM(Valor_Venda_Sem_Frete_Sem_IVA)`	Métrica calculada dedicada; filtros de categoria; navegações *roll up* temporal e geográfico.
10	Vendas com IVA e quantidades ao fim de semana no 2º trimestre de 2025 para "Acessórios", "Amplificadores" e "Teclados", por zona do fornecedor (*drill down* para fornecedor) e por zona do cliente (*drill down* para cliente).	`Dim_Data` (`Trimestre` , `Fim_De_Semana`), `Dim_Produto` (`Nome_Familia`), `Dim_Fornecedor` (`Zona_Fornecedor` ➔ `Nome_Fornecedor`), `Dim_Cliente` (`Zona` ➔ `Nome_Cliente`)	`SUM(Valor_Venda_Com_IVA)` , `SUM(Quantidade)`	Filtro por `Fim_De_Semana = 1` e `Trimestre = 2` ; *drill downs* independentes em ambos os eixos geográficos.

8. Conclusão da 1ª Parte e Transição para a Implementação (Parte 2)

O trabalho desenvolvido nesta 1ª Parte cumpriu integralmente os objetivos teóricos e de engenharia conceptual estabelecidos para o projeto da More Rhythm, SA:

1. **Robustez da Arquitetura:** Foi formalizada uma arquitetura em 4 camadas que assegura a separação de responsabilidades e garante que a exploração analítica em Power BI decorre sem impacto nos sistemas de faturação diária.
2. **Conformidade com a Metodologia Kimball:** O desenho dimensional centrado na linha individual de fatura proporciona o grão mais elementar possível, prevenindo perdas de contexto analítico e conferindo total flexibilidade para responder a questões presentes e futuras da administração.
3. **Resolução de Desafios Críticos do Negócio:**
4. O desfasamento entre o frete da fatura e as análises por produto foi resolvido através de um algoritmo formal de rateio proporcional, garantindo a conservação estrita dos totais.
5. Os problemas de qualidade nos dados de clientes (duplicações e registos com grafias aproximadas) foram endereçados por meio de normalização sintática e *fuzzy matching* na *Staging Area*.
6. A perspetiva de expansão internacional para o Reino Unido foi integrada na conceção da `Dim_Moeda` e nos mecanismos de conversão cambial pontual para a moeda de uniformização Euro (`EUR`).
7. **Isolamento de Erros:** As estruturas de auditoria e rejeição na *Staging Area* garantem que registos anómalos não automatizáveis são desviados e auditados, preservando a integridade e credibilidade dos dados no *Data Mart*.

Os artefactos concetuais e técnicos aqui especificados constituem a base sólida e vinculativa sobre a qual será desenvolvida a **2ª Parte do Trabalho Prático**, nomeadamente a implementação dos pacotes ETL em SQL Server Integration Services (SSIS), a criação dos scripts SQL físicos e a construção dos modelos semânticos e relatórios em Power BI.