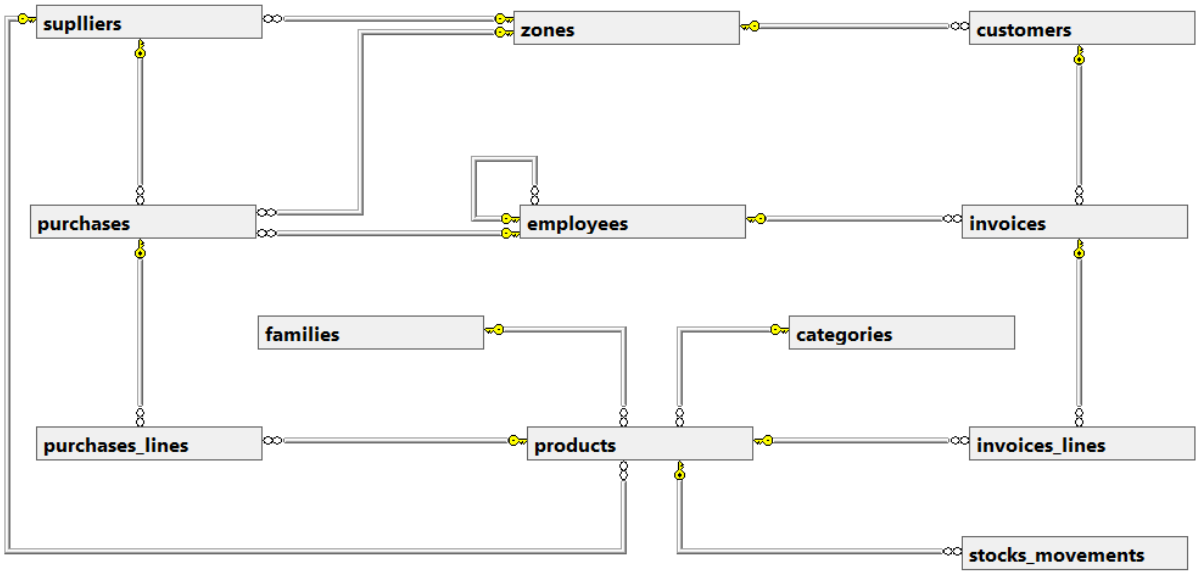
Descrição do problema

O presente trabalho tem por objetivo o desenvolvimento de um *data mart*, com base nos dados das vendas (*i.e.*, faturação) efetuadas por uma empresa líder, a nível nacional, na distribuição e comercialização de instrumentos musicais (*More Rhythm*, SA). A empresa possui a sua sede no Porto. As vendas da empresa abrangem todo o território nacional e, pontualmente, também Espanha. O sistema informático suporta as diversas atividades da empresa a nível operacional (*e.g.*, vendas/faturação, compras, gestão de stocks). Na figura seguinte apresenta-se o modelo de dados subjacente a esse sistema informático.



A gestão da empresa pretende que se desenvolva um *data mart* que permita a realização de diversas análises históricas às vendas efetuadas a clientes. No desenvolvimento do *data mart* há alguns aspetos a ter em consideração, relacionados com os dados que se encontram na base de dados do sistema operacional:

- O mesmo cliente pode ter sido introduzido erradamente em duplicado, estando representado com identificadores diferentes na base de dados. Para além disso, o mesmo cliente pode ter sido introduzido em duplicado de uma forma que não é rigorosamente igual.
- Os custos de expedição encontram-se ao nível da fatura e não ao nível de cada linha/produto que faz parte da fatura.

- O sistema operacional regista sempre a data e hora em que um registo é inserido numa tabela. Igualmente, sempre que ocorre uma alteração a um atributo, a respetiva data e hora em que tal ocorreu também é registada.

Requisitos do trabalho

Nos pontos seguintes enumeram-se os requisitos que devem ser respeitados no trabalho a efetuar:

- Desenvolver um processo de análise dimensional, a fim de definir e criar o esquema conceptual para o *data mart*, com base na informação atrás disponibilizada e seguindo a metodologia de *Kimball*. Todas as opções tomadas na criação do modelo dimensional devem ser devidamente justificadas no relatório a produzir. O *data mart* a desenvolver deverá ser concebido de modo que permita a realização de consultas/análises **aos dados das vendas no nível de granularidade mais elementar**, de modo a possibilitar a maior flexibilidade possível para a realização dessas análises de dados.
- Proceder à extração, integração, transformação, limpeza e carregamento dos dados no *data mart*, por intermédio de um *Integration Services Project do Visual Studio* e dos componentes mais adequados que este disponibiliza para as referidas tarefas. Mais especificamente, pretende-se que:
    - Todo o processo de extração, integração, transformação, limpeza e carregamento dos dados deve ser o mais eficiente possível. Por questões de confidencialidade relacionadas com o negócio, apenas foi disponibilizada para a construção do *data mart* uma amostra dos dados que se encontram no sistema operacional. No entanto, o volume de registos é bastante elevado. Embora seja uma amostra, é totalmente representativa dos dados globais que se encontram no sistema operacional e da realidade subjacente.
    - Os dados podem estar afetados por problemas de qualidade (por exemplo: valores em falta em atributos supostamente de preenchimento obrigatório; valores que violam o domínio do atributo; valores que constituem violações a restrições de integridade). Para a identificação dos problemas que possam existir sugere-se a realização de um processo de *Data Profiling* prévio sobre os dados.
    - O processo de transformação e limpeza deve filtrar todos os registos que se encontram afetados por problemas de qualidade. Assim, qualquer registo afetado por problemas de qualidade, cuja correção não seja possível de ser automatizável, não deve ser carregado no *data mart*, sendo armazenado em tabelas especialmente

criadas para o efeito na *Staging Area*. A correção destes problemas e posterior carregamento desses registos para o *data mart* fica excluída do âmbito deste trabalho.

- A fase de limpeza de dados deve ser efetuada de modo a eliminar todas as redundâncias (registos duplicados iguais ou aproximadamente iguais) que possam existir nos dados, oriundos do sistema operacional.
- O carregamento dos dados no *data mart* (tabelas de dimensões e tabela de factos) deve ser concebido de modo a poder ser executado de forma incremental, isto é, em cada execução só serem carregados os dados novos e atualizados os que já existem, caso tenham sofrido alterações.
- A médio prazo perspetiva-se que a empresa expanda as suas operações para outros países da união europeia e abra a sua primeira sucursal no estrangeiro, mais concretamente no Reino Unido. Assim, o *data mart* a desenvolver tem de ter esta realidade em conta, considerando o Euro como a moeda de uniformização que permitirá realizar análises de dados que envolvam moedas diferentes.
- O *Integration Services Project* deve ser elaborado de modo que não existam caminhos (*paths*) absolutos nos diversos componentes. Todos estes caminhos têm de ser configuráveis mediante a sua especificação num ficheiro de parametrizações, assim como: nome do servidor de base de dados do sistema operacional; nome da base de dados do sistema operacional; nome do servidor de base de dados do *data mart* e da *staging area* (mesmo servidor para ambas); nome da base de dados do *data mart*; e, nome da base de dados da *staging area*.
- Deve ser criado um repositório no *GitHub* onde conste toda a documentação elaborada durante o desenvolvimento do projeto, bem como o *Integration Services Project* cujo desenvolvimento deve ser realizado de modo colaborativo entre ambos os elementos do grupo. A avaliação do trabalho terá em conta o contributo individual de cada elemento, com base nos *commits* efetuados no repositório e no seu conteúdo. O repositório será designado **ARMDD_26-27_XXXXXXX_YYYYYYY**, em que **XXXXXXX** e **YYYYYYY** representam os **números dos alunos** que constituem o grupo. No repositório deverá ser concedido permissões de acesso ao docente da aula PL a que pertencem os alunos do grupo.

- Proceder à elaboração de 20 análises multidimensionais de dados sobre o armazém de dados criado utilizando a ferramenta *PowerBI*. Das 20 análises de dados, 10 são realizadas "à

escolha", mas devem possuir graus de dificuldade diferentes e têm de incidir sobre as hierarquias que existam nos dados. As restantes 10 análises de dados encontram-se apresentadas de seguida, representando análises típicas que a gestão da empresa pretende efetuar às vendas a clientes. Note-se que estas 10 análises são meramente indicativas, pelo que o *data mart* não pode ser criado unicamente para lhes dar resposta.

1. Valores totais com IVA das vendas efetuadas no primeiro semestre de 2025, detalhados por zona geográfica e por categoria de produto.
2. Valores totais dos custos de expedição (frete) despendidos no transporte dos produtos durante o mês de fevereiro de 2025, detalhados por cidade do cliente e por família de produto.
3. Quantidades dos produtos vendidos no primeiro trimestre de 2025, detalhados por fornecedor e por empregado.
4. Valores totais das vendas sem IVA efetuadas e respetivos valores de IVA pagos durante o ano de 2025, detalhados por cliente e funcionário.
5. Valores totais das vendas com IVA efetuadas no último dia de cada mês do ano de 2025, detalhados por categoria de produto, com possibilidade de análise detalhada (i.e., *drill down*) até ao nível do produto.
6. Valores totais com IVA, referentes às vendas efetuadas a clientes da zona Norte na 6ª semana do ano de 2025, detalhados por família de produto, com possibilidade de análise detalhada (i.e., *drill down*) até ao nível do produto.
7. Quantidades referentes às vendas ocorridas no 1º quadrimestre de 2025, detalhados por cliente e por produto, com possibilidade de análise agregada (i.e., *roll up*) apenas ao nível do tipo de cliente.
8. Valores totais do IVA faturados durante a primavera de 2025, detalhados por cidade do cliente e por família de produto.
9. Valores totais das vendas sem IVA e sem custos de expedição (frete) por cliente, com possibilidade de análise agregada (i.e., *roll up*) apenas ao nível da zona (do cliente), e por mês do ano de 2025, com possibilidade de análise agregada (i.e., *roll up*) apenas ao nível do trimestre, unicamente para produtos pertencentes às categorias "Ar", "Cordas" e "Membranas".
10. Valores totais das vendas com IVA e respetivas quantidades ocorridas ao fim-de-semana, no 2º trimestre de 2025, dos produtos pertencentes às famílias

"Acessórios", "Amplificadores" e "Teclados", detalhados por zona do fornecedor, com possibilidade de análise detalhada (i.e., *drill down*) até ao nível do fornecedor e por zona do cliente, com possibilidade de análise detalhada (i.e., *drill down*) até ao nível do cliente.

A realização do trabalho é feita em **grupos de dois alunos** e envolve duas **partes complementares**.

Na **1ª parte** pretende-se que seja elaborado: arquitetura do armazém de dados para a situação descrita; modelo dimensional subjacente (com a apresentação dos atributos e respetivos tipos de dados para cada dimensão e tabela de factos); estruturas de dados (i.e., tabelas; ficheiros) a criar na *staging area*; mapeamento de dados entre os sistemas fonte e a *staging area* e entre a *staging area* e o armazém de dados (para os atributos das dimensões deve ser apresentada a estratégia de *Slowly Changing Dimension* (SCD); e, eventuais operações de transformação e limpeza de dados a realizar nos diversos atributos). Estes artefactos devem resultar na elaboração de um relatório.

Na 2ª parte do trabalho pretende-se a implementação do armazém de dados, com a correspondente implementação dos processos de extração, transformação, limpeza, integração e carregamento dos dados. Esta parte deve ser documentada através da realização de um relatório final no qual constem todos os elementos relevantes para a avaliação final do trabalho, como: arquitetura do armazém de dados (final); modelo dimensional (final); estruturas de dados criadas na *staging area* (final); mapeamento de dados entre os sistemas fonte e a *staging area* e entre a *staging area* e o armazém de dados (o que inclui que para os atributos das dimensões seja apresentada a estratégia de *Slowly Changing Dimension* (SCD) (final); processos de extração, transformação, limpeza, integração e carregamento de dados efetuados; *scripts* SQL criados; análises dimensionais efetuadas mediante a apresentação das respetivas consultas; justificação das opções tomadas; melhoramentos possíveis; etc.

Prazo e Forma de Entrega da 1ª parte do Trabalho:

- O **relatório** tem de ser **submetido no Moodle** até às **23h59** do dia **15 de novembro de 2026**.
- O trabalho deve ser submetido sob a forma de um **único ficheiro PDF**, com o seguinte nome: **XXXXXXX_YYYYYYY.pdf**, em que XXXXXXX e YYYYYYY representam os **números dos alunos** que constituem o grupo.

Prazo e Forma de Entrega da 2ª parte do Trabalho:

- **O Trabalho** (relatório final + *integration services project*) tem de ser **submetido no Moodle** até às **23h59** do dia **13 de dezembro de 2026**.
- O trabalho deve ser submetido sob a forma de um **único ficheiro ZIP**, com o seguinte nome: **XXXXXXX_YYYYYYY.zip**, em que XXXXXXX e YYYYYYY representam os **números dos alunos** que constituem o grupo.
- A discussão do trabalho será efetuada com **ambos os elementos do grupo obrigatoriamente presentes**, em data e hora a combinar oportunamente.

O **incumprimento do prazo de entrega** implica uma **penalização na nota**, dessa parte do Trabalho, **de 20% por cada dia de atraso.**